Competição Kaggle – Parte 1 (CPT_1)

Análise Exploratória de Dados (EDA)

Arthur H. de O. Petroli / RA: 2408732
Deivid Da Silva Galvão / RA: 2408740
UTFPR – Engenharia da Computação
Disciplina de Mineração de Dados

13 de maio de 2025

Resumo

Este relatório apresenta a análise exploratória de dados (EDA) realizada sobre o conjunto de dados da competição disponibilizada na plataforma Kaggle (*link*). O objetivo desta etapa é entender as principais características do dataset e levantar insights iniciais que possam orientar futuras etapas de pré-processamento e modelagem preditiva.

1 Introdução

Nesta primeira etapa do projeto, foi realizada uma análise exploratória sobre o conjunto de dados de estabelecimentos na cidade de Toronto, disponibilizado na competição da disciplina. O objetivo é identificar padrões, detectar valores faltantes, compreender a distribuição das variáveis e possíveis relações entre atributos.

2 Características Gerais

O conjunto de treino possui **17.582 instâncias** e **13 atributos**, enquanto o conjunto de teste possui **1.324 instâncias** e **12 atributos** (sem a variável alvo `destaque`).

A Tabela abaixo resume os tipos de variáveis:

Tabela 1: Distribuição dos tipos de variáveis

Tipo de Dado	Quantidade	Exemplos
Numéricas	5	latitude, longitude, review_count
Categóricas	8	name, address, attributes

3 Valores Faltantes

Foram identificadas colunas com valores ausentes, conforme Tabela 2. A coluna `hours` apresenta o maior número de nulos (4.677), seguida por `attributes` (2.568).

Tabela 2: Quantidade de valores nulos por coluna

Coluna	Nulos
address	287
postal_code	108
attributes	2.568
categories	27
hours	4.677

4 Distribuição das Variáveis Numéricas

- **latitude**: levemente assimétrica à direita, centrada entre 43.64 e 43.68 — coerente com Toronto.
- **longitude**: simétrica, pico em -79.4 — sugere concentração geográfica.
- **review_count**: extremamente assimétrica — poucos estabelecimentos com muitas avaliações.

Sugere-se aplicar normalização (ex: log) em `review_count` e usar `latitude`/`longitude` em clusters ou distância geográfica.

5 Cardinalidade das Variáveis Categóricas

- **name**: 14.775 nomes únicos — alta cardinalidade.
- **address**: 13.974 endereços — alta cardinalidade.
- **postal_code**: 5.210 códigos — pode ser útil para agrupamento.
- **attributes**: 11.141 combinações únicas — algumas chaves se repetem, como:
  - `ByAppointmentOnly`: True
  - `GoodForKids`: True

Conclusão: variáveis com alta cardinalidade devem ser tratadas com cuidado. Algumas podem ser descartadas; outras, desmembradas e codificadas.

6 Correlação entre Variáveis Numéricas

A Figura 1 apresenta o mapa de calor da matriz de correlação.

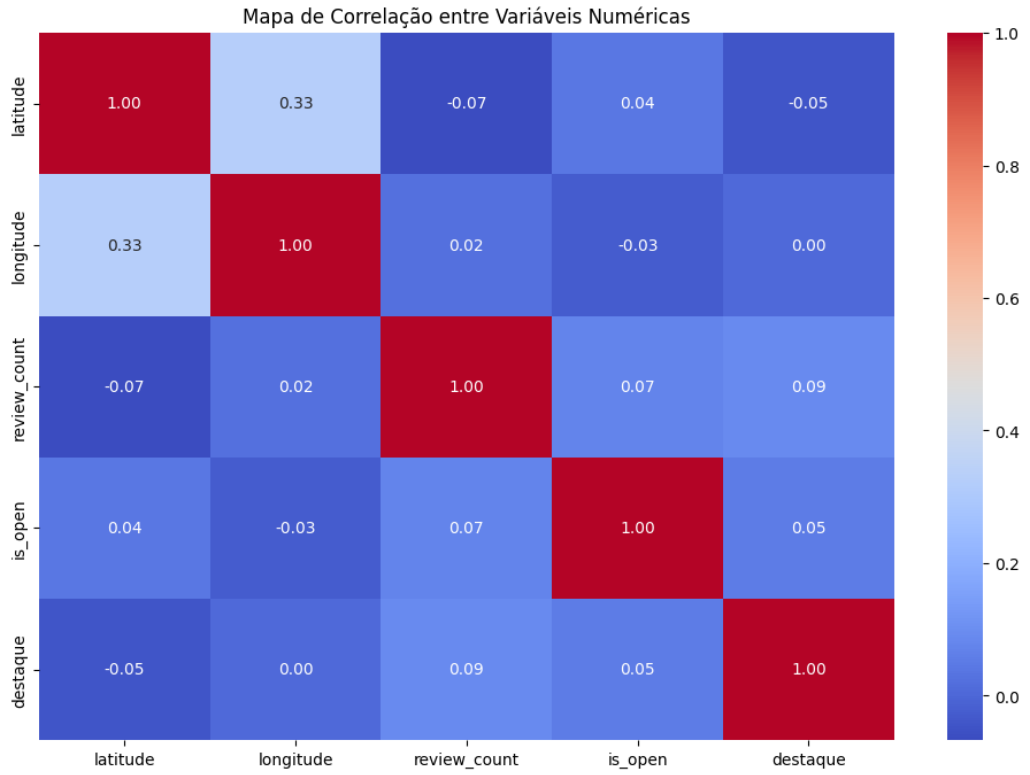


Figura 1: Mapa de Correlação entre Variáveis Numéricas

Interpretação:

- `latitude` e `longitude`: correlação de 0.33 — leve relação espacial.
- `review_count`: baixa correlação com outras variáveis — comportamento independente.
- `is_open` e `destaque`: correlação fraca (0.05).

7 Conclusões e Próximos Passos

- Muitas colunas possuem alta cardinalidade e valores ausentes.
- Algumas variáveis (ex: review_count) têm distribuições enviesadas.
- As correlações entre variáveis numéricas são fracas.

Próximos passos:

- Pré-processamento (tratamento de nulos, encoding de categóricas).
- Seleção e extração de atributos relevantes.
- Utilização de modelos preditivos.