Universidade Tecnológica Federal do Paraná
Departamento de Informática

Mineração de Dados
Thiago H Silva

Exercício 3

1- Utilize o dataset “titanic.csv”, disponível no moodle. Considere 70% das instâncias para treino e 30% para validação. Construa um modelo utilizando Árvore de Decisão para prever se uma pessoa sobreviveu ou não.

a) Mostre a árvore encontrada.
b) Qual a acurácia do modelo obtida com os dados de validação?

2- Considere ainda uma árvore de decisão para classificar se um indivíduo sobreviveu ou não com base no dataset “titanic.csv”. Qual o resultado médio de acurácia utilizando a estratégia de validação cruzada 10-fold? Discuta os resultados.

3- Ainda considerando o dataset “titanic.csv”, construa um modelo utilizando k-NN para prever se uma pessoa sobreviveu ou não. Considere diferentes valores de k vizinhos: k={2,3,4,5,6,7}. Houve variação significativa nos diferentes modelos testados? Algum deles foi melhor do que a estratégia baseada em árvore de decisão?